

# 《数值分析》7

- Hilbert矩阵的病态性
- 向量范数与矩阵范数
- 矩阵的条件数概念
- Hilbert矩阵的条件数



Hilbert

## 引例. Hilbert矩阵的病态性

$$A = \begin{bmatrix} 1 & 1/2 & 1/3 & 1/4 \\ 1/2 & 1/3 & 1/4 & 1/5 \\ 1/3 & 1/4 & 1/5 & 1/6 \\ 1/4 & 1/5 & 1/6 & 1/7 \end{bmatrix} \quad b = \begin{bmatrix} 1 \\ 2 \\ 1.41 \\ 2 \end{bmatrix}$$

方程组  $Ax = b$  的解为  $x$

方程组  $Ax = b_1$  的解为  $x_1$

$$b_1 = \begin{bmatrix} 1 \\ 2 \\ 1.42 \\ 2 \end{bmatrix}$$

数据计算结果

$$x - x_1 = [-2.4 \quad 27.0 \quad -64.8 \quad 42.0]^T$$

**定义3.1:** 设  $R^n$  是  $n$  维向量空间, 如果对任意  $x \in R^n$ , 都有一个实数与之对应, 且满足如下三个条件:

(1) 正定性:  $\|x\| \geq 0$ , 且  $\|x\| = 0 \iff x = 0$  ;

(2) 齐次性:  $\|\lambda x\| = |\lambda| \|x\|$   $\lambda$  为任意实数

(3) 三角不等式:  $\|x + y\| \leq \|x\| + \|y\|$  ( $y \in R^n$ )

则称  $\|x\|$  为向量  $x$  的范数 .

为什么定义向量范数



**注:** 向量范数是向量长度概念的推广. 例如

$$\sqrt{\sum_{i=1}^n x_i^2} = \sqrt{x_1^2 + x_2^2 + \cdots + x_n^2}$$

是向量  $x$  的范数

向量2范数

常用的范数:  $\|x\|_1 = \sum_{i=1}^n |x_i| = |x_1| + |x_2| + \cdots + |x_n|$

广义:  
p范数

$$\|x\|_2 = \sqrt{\sum_{i=1}^n x_i^2} = \sqrt{x_1^2 + x_2^2 + \cdots + x_n^2}$$

$$\|x\|_\infty = \max_{1 \leq i \leq n} |x_i| = \max(|x_1|, |x_2|, \cdots, |x_n|)$$

例1. 证明  $\|x\|_2$  是  $R^n$  上的一种范数

先证明柯西不等式:  $|x^T y| \leq \|x\|_2 \cdot \|y\|_2$

对任意实数  $\lambda$ , 有  $(x - \lambda y)^T (x - \lambda y) \geq 0 \rightarrow$

判别式

$$x^T x - 2\lambda x^T y + \lambda^2 y^T y \geq 0$$

$$|x^T y|^2 - (x^T x)(y^T y) \leq 0 \rightarrow |x^T y| \leq \|x\|_2 \cdot \|y\|_2$$

根据上式的最小值依然大于0,

求导得到最小值, 推导出来

$$\begin{aligned}
 \|x + y\|_2^2 &= (x + y)^T (x + y) \\
 &= x^T x + x^T y + y^T x + y^T y \\
 &\leq \|x\|_2^2 + 2|x^T y| + \|y\|_2^2 \\
 &\leq \|x\|_2^2 + 2\|x\|_2\|y\|_2 + \|y\|_2^2
 \end{aligned}$$

$$\|x + y\|_2 \leq \|x\|_2 + \|y\|_2 \quad (\text{三角不等式成立})$$

$$\|x\|_2 = \sqrt{x_1^2 + x_2^2 + \cdots + x_n^2} \geq 0 \quad (\text{正定性成立})$$

$$\|\lambda x\|_2 = \sqrt{\sum_{i=1}^n (\lambda x_i)^2} = |\lambda| \sqrt{\sum_{i=1}^n x_i^2} = |\lambda| \cdot \|x\|_2$$

$$(\text{齐次性成立})$$

## 向量范数的性质

**定义：**如果 $R^n$ 中有两个范数  $\|x\|_s$  与  $\|x\|_t$ ，存在常数 $m$ ， $M>0$ ，使对任意 $n$ 维向量 $x$ ，有

$$m\|x\|_s \leq \|x\|_t \leq M\|x\|_s$$

则称这两个范数等价.

**性质：**对两种等价范数而言，某向量序列在其中一种范数意义下收敛时，则在另一种范数意义下也收敛。

**注：**今后研究向量序列的收敛性时，可在任何一种范数意义下研究。

# 正交变换下向量2-范数不变性

$A^T A = I$  (正交变换性质),  $y = Ax \rightarrow \|y\|_2 = \|x\|_2$




$$y^T y = (Ax)^T (Ax) = x^T A^T A x = x^T x$$

$$\rightarrow \|y\|_2 = \sqrt{y^T y} = \sqrt{x^T x} = \|x\|_2$$

举例:

$$\begin{bmatrix} u_k \\ v_k \end{bmatrix} = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix} \begin{bmatrix} x_k \\ y_k \end{bmatrix}$$

# 例1. 范数意义下的单位向量: $X=[x_1, x_2]^T$



$$\|X\|_1 = |x_1| + |x_2|$$

$$\|X\|_2 = \sqrt{x_1^2 + x_2^2}$$

$$\|X\|_\infty = \max\{|x_1|, |x_2|\}$$



**例2.** 设  $x = (x_1, x_2, \dots, x_n)^T$ , 证明

$$\|x\|_{\infty} \leq \|x\|_1 \leq n \|x\|_{\infty}$$

证明:  $\|x\|_1 = |x_1| + |x_2| + \dots + |x_n|$

$$\max_{1 \leq k \leq n} |x_k| \leq \|x\|_1 \leq n \times \max_{1 \leq k \leq n} |x_k|$$

所以  $\|x\|_{\infty} \leq \|x\|_1 \leq n \|x\|_{\infty}$

三角不等式的变形:  $\|x - y\| \geq \left| \|x\| - \|y\| \right|$

$$\|x\| = \|x - y + y\| \leq \|x - y\| + \|y\|$$

$$\|x\| - \|y\| \leq \|x - y\| \quad \|y\| - \|x\| \leq \|x - y\|$$

$$-\|x - y\| \leq \|x\| - \|y\| \leq \|x - y\|$$

**定义3.2** 对  $A \in R^{n \times n}$ , 存在实数  $\|A\|$  满足:

(1) 正定性:  $\|A\| \geq 0$ , 且  $\|A\| = 0 \Leftrightarrow A = 0$  ;

(2) 齐次性:  $\|\lambda A\| = |\lambda| \|A\|$   $\lambda$  为任意实数

(3) 三角不等式:  $\|A + B\| \leq \|A\| + \|B\|$  ( $B \in R^{n \times n}$ )

(4) 相容性:  $\|A \cdot B\| \leq \|A\| \cdot \|B\|$  ( $\forall A, B \in R^{n \times n}$ )

则称  $\|A\|$  是矩阵  $A$  的一个范数.

**Frobenius范数**  $\|A\|_F = \left( \sum_{j=1}^n \sum_{i=1}^n a_{ij}^2 \right)^{1/2}$

# 矩阵算子范数的概念

设  $\|x\|$  是  $R^n$  上的向量范数,  $A \in R^{n \times n}$ , 则  $A$  的非负函数

$$\|A\| = \max_{x \neq 0} \frac{\|Ax\|}{\|x\|}$$

称为矩阵  $A$  的 算子范数

**注1:** 矩阵算子范数由向量范数诱导出, 如

$$\|A\|_2 = \max_{x \neq 0} \frac{\|Ax\|_2}{\|x\|_2} \quad \text{或} \quad \|A\|_2 = \max_{\|x\|_2=1} \|Ax\|_2$$

**注2:**  $A^{-1}$  的算子范数可表示为  $\left( \min_{x \neq 0} \frac{\|Ax\|}{\|x\|} \right)^{-1}$

$$\|A^{-1}\| = \max_{x \neq 0} \frac{\|A^{-1}x\|}{\|x\|} = \max_{y \neq 0} \frac{\|y\|}{\|Ay\|} = \frac{1}{\min_{y \neq 0} \frac{\|Ay\|}{\|y\|}}$$

$$\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}| \quad \text{“1-范数” (列和范数)}$$

$$\|A\|_\infty = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}| \quad \text{无穷大范数(行和范数)}$$

$$\|A\|_2 = \sqrt{\lambda_{\max}(A^T A)}$$

证: 由算子范数概念  $\|A\|_2 = \max_{\|x\|_2=1} \|Ax\|_2$

$$\|Ax\|_2^2 = x^T A^T A x$$

由于  $A^T A$  是对称矩阵, 故存在正交特征向量系  $v_1, \dots, v_n$  设对应的特征值为  $\lambda_1, \dots, \lambda_n$

单位向量  $x$  可被特征向量系所表示

$$x = \sum_{k=1}^n c_k v_k$$

$$x^T x = \left( \sum_{k=1}^n c_k v_k^T \right) \left( \sum_{k=1}^n c_k v_k \right) = \sum_{k=1}^n c_k^2 = 1$$

$$\begin{aligned} \|Ax\|_2^2 &= x^T A^T Ax = \left( \sum_{k=1}^n c_k v_k^T \right) \left( \sum_{k=1}^n c_k \lambda_k v_k \right) \\ &= \sum_{k=1}^n c_k^2 \lambda_k \leq \sum_{k=1}^n c_k^2 \lambda_{\max}(A^T A) = \lambda_{\max}(A^T A) \end{aligned}$$

$$\Rightarrow \|Ax\|_2 \leq \sqrt{\lambda_{\max}(A^T A)}$$

根据定义，取对应特征向量  $\Rightarrow \|A\|_2 = \sqrt{\lambda_{\max}(A^T A)}$

# 矩阵的条件数概念

方程组  $Ax = b$ , 右端项  $b$  有一扰动  $\delta b$   
引起方程组解  $x$  的扰动  $\delta x$

设  $x$  是方程组  $Ax = b$  的解, 则有

$$A(x + \delta x) = b + \delta b$$

化简, 得  $A\delta x = \delta b$   $\delta x = A^{-1}\delta b$

$$\|\delta x\| \leq \|A^{-1}\| \|\delta b\|$$

由  $Ax = b$  得  $\|b\| \leq \|A\| \|x\|$   $\frac{1}{\|x\|} \leq \frac{\|A\|}{\|b\|}$

所以  $\frac{\|\delta x\|}{\|x\|} \leq (\|A\| \cdot \|A^{-1}\|) \frac{\|\delta b\|}{\|b\|}$

## 定义: 条件数

$$\text{Cond}(A) = \|A\| \cdot \|A^{-1}\|$$

$$\text{或 } C(A) = \|A\| \cdot \|A^{-1}\|$$

当条件数很大时,方程组  $Ax = b$  是病态问题;

当条件数较小时,方程组  $Ax = b$  是良态问题

# 著名病态矩阵:

$$A = \begin{bmatrix} 1 & 1/2 & 1/3 & 1/4 \\ 1/2 & 1/3 & 1/4 & 1/5 \\ 1/3 & 1/4 & 1/5 & 1/6 \\ 1/4 & 1/5 & 1/6 & 1/7 \end{bmatrix}$$

阶数	2	4	6
条件数1	27	$19.4 \times 10^5$	$9.8 \times 10^8$
条件数2	19.2815	$1.5 \times 10^4$	$1.4 \times 10^7$
条件数 $\infty$	27	$19.4 \times 10^5$	$9.8 \times 10^8$